Perhitungan Manual

SMOTE dan Random Forest

Dijelaskan langkah demi langkah, dengan contoh yang mudah diikuti
dan rumus matematika yang sesungguhnya dipakai komputer

1. Mengapa Kita Perlu Menghitung dengan Tangan?

Bayangkan kamu sedang duduk di ruang dosen pembimbing. Beliau bertanya: *"Program ini katanya bisa menebak pasien mana yang pengobatannya gagal. Coba jelaskan, bagaimana caranya sampai ia bisa menebak?"*

Komputer, sebenarnya, tidak lebih pintar dari kita. Ia hanya mengerjakan hitungan-hitungan matematika dengan sangat teliti dan sangat cepat. Kalau kita bisa menirukan hitungan itu dengan angka kecil di kertas, berarti kita benar-benar memahami apa yang terjadi di dalam "kotak hitam" program tersebut.

Di dokumen ini kita akan menempuh perjalanan itu pelan-pelan. Kita pakai contoh sangat sederhana — hanya **8 pasien** dan **3 ciri** — supaya setiap angka bisa kita hitung dengan tangan, sama seperti mengajari seorang anak sekolah dasar. Tetapi rumus yang kita pakai adalah **rumus yang asli**, yang benar-benar ada di dalam program.

Perjalanan kita punya lima langkah besar:

Langkah 1. Menyiapkan data dan mengubah kata menjadi angka.

Langkah 2. Mengukur seberapa "mirip" dua pasien.

Langkah 3. Menambah data dengan **SMOTE**.

Langkah 4. Membangun pohon keputusan, lalu menggabungkannya menjadi **Random Forest**.

Langkah 5. Menilai seberapa tepat tebakan itu.

2. Langkah 1 — Menyiapkan Data

2.1 Delapan pasien kita

Kita punya catatan delapan pasien MDR-TB. Setiap pasien punya tiga ciri, dan satu kenyataan (benar atau tidaknya pengobatan):

Pasien	Usia	Kepatuhan Minum Obat	Berat Badan	Hasil
P1	30	Patuh	50	Berhasil
P2	40	Patuh	55	Berhasil
P3	25	Patuh	60	Berhasil
P4	55	Patuh	45	Berhasil
P5	50	Tidak Patuh	55	Berhasil
P6	45	Tidak Patuh	60	Tidak Berhasil
P7	60	Tidak Patuh	65	Tidak Berhasil
P8	35	Tidak Patuh	70	Tidak Berhasil

Perhatikan: ada **5 pasien Berhasil** dan hanya **3 pasien Tidak Berhasil**. Kelompok "Tidak Berhasil" jauh lebih sedikit. Inilah yang diistilahkan **data tidak seimbang** (*imbalanced data*). Masalahnya, komputer cenderung mengabaikan kelompok yang sedikit — padahal justru kelom-

pok itulah yang paling ingin kita deteksi (karena pasien yang gagal pengobatan perlu segera ditolong). Nanti SMOTE akan membantu mengatasi hal ini.

2.2 Mengubah kata menjadi angka

Komputer tidak mengerti kata seperti "Patuh". Ia hanya mengerti angka. Maka setiap kata kita ganti dengan bilangan, dengan aturan sederhana:

Kata	Angka
Patuh	1
Tidak Patuh	0
Berhasil	0
Tidak Berhasil	1

Proses ini disebut **encoding**. Hasilnya menjadi tabel angka seperti ini:

Pasien	Usia	Kepatuhan	Berat Badan	Hasil
P1	30	1	50	0
P2	40	1	55	0
P3	25	1	60	0
P4	55	1	45	0
P5	50	0	55	0
P6	45	0	60	1
P7	60	0	65	1
P8	35	0	70	1

Mengapa Berhasil

Angka 0 dan 1 hanyalah label, sama seperti nomor urut. Yang penting konsisten. Kebetulan di penelitian ini "Tidak Berhasil" dijadikan kelas yang *positif* (yang ingin dideteksi), sehingga ia dilabeli 1.

2.3 Menyamakan skala (normalisasi)

Ada satu masalah halus. Usia berkisar 25–60, sedangkan kepatuhan hanya 0 atau 1. Kalau kita mengukur "jarak" mentah-mentah, angka usia yang besar akan mendominasi dan ciri kepatuhan yang sebenarnya penting jadi tidak terlihat. Karena itu, sebelum dihitung, semua ciri *disamakan skalanya*. Rumus yang dipakai adalah **skor-z**:

$$z = \frac{x - \mu}{\sigma}$$

Artinya: setiap nilai x dikurangi rata-rata kolomnya (μ), lalu dibagi dengan simpangan bakunya (σ). Hasilnya, semua ciri berada pada skala yang sebanding, sehingga tidak ada yang mendominasi.

Catatan

Agar mudah diikuti, pada perhitungan tangan ini kita akan terus memakai **angka asli** (bukan hasil normalisasi). Idenya sama persis; komputer melakukannya otomatis. Kita cukup tahu bahwa langkah ini ada dan penting.

3. Langkah 2 — Mengukur “Kemiripan” dengan Jarak

3.1 Idenya

Untuk membuat data tambahan, SMOTE perlu tahu pasien mana yang “mirip”. Dua pasien dianggap mirip jika jaraknya kecil. Jarak yang dipakai adalah **jarak Euclidean**, yaitu jarak lurus antara dua titik — seperti menarik garis lurus dengan penggaris, hanya saja di ruang yang punya banyak ciri.

3.2 Rumus aslinya

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Mari kita bedah simbol demi simbol:

- $d(\mathbf{x}, \mathbf{y})$ — jarak antara pasien $\mathbf{x}$ dan pasien $\mathbf{y}$.
- x_i dan y_i — nilai ciri ke-i (misalnya usia, atau berat badan).
- n — banyaknya ciri. Di contoh kita $n = 3$ (usia, kepatuhan, berat badan).
- $\sum$ — tanda “jumlahkan semuanya”.
- $(\,\cdot\,)^2$ — setiap selisih dikuadratkan (supaya tanda minus tidak saling menghapus).
- $\sqrt{\cdot}$ — diakhiri dengan akar, sehingga kembali ke satuan semula.

3.3 Mari menghitung: jarak P6 dan P7

Ambil pasien P6 (45; 0; 60) dan P7 (60; 0; 65). Kita masukkan ke rumus, ciri demi ciri:

Ciri	Selisih	Dikuadratkan
Usia	$45 - 60 = -15$	$(-15)^2 = 225$
Kepatuhan	$0 - 0 = 0$	$0^2 = 0$
Berat	$60 - 65 = -5$	$(-5)^2 = 25$

$$d = \sqrt{225 + 0 + 25} = \sqrt{250} \approx 15{,}81$$

Jadi jarak P6 dan P7 sekitar 15,81. Semakin kecil angka ini, semakin mirip kedua pasien.

Pasangan	Perhitungan	Jarak
P6 – P7	$\sqrt{250}$	15,81
P6 – P8	$\sqrt{200}$	14,14
P7 – P8	$\sqrt{650}$	25,50

Pasien yang paling mirip dengan P6 adalah **P8**, karena jaraknya paling kecil (14,14). Hubungan “bertetangga” inilah yang nanti dipakai SMOTE.

4. Langkah 3 — SMOTE: Membuat Pasien Baru

4.1 Apa yang dilakukan SMOTE?

SMOTE (*Synthetic Minority Over-sampling Technique*) menambah jumlah pasien kelompok minoritas dengan cara **membuat pasien baru buatan**. Bedanya dengan menggandakan biasa: pasien baru ini *tidak sama persis* dengan yang lama — ia diletakkan di antara dua pasien minoritas yang berdekatan. Ibaratnya, kalau ada dua siswa yang mirip, kita membuat "siswa baru" yang mirip keduanya.

4.2 Rumus aslinya

$$\mathbf{x}_{\text{baru}} = \mathbf{x}_i + \lambda \cdot \left(\mathbf{x}_{zi} - \mathbf{x}_i\right), \qquad \lambda \sim U(0,1)$$

Penjelasannya:

- $\mathbf{x}_i$ — pasien minoritas yang kita pilih sebagai titik awal.
- $\mathbf{x}_{zi}$ — salah satu "tetangga" terdekatnya (pasien minoritas lain yang mirip).
- λ (*lambda*) — angka acak antara 0 dan 1. Kalau $\lambda = 0{,}5$, pasien baru diletakkan tepat di tengah-tengah. Di contoh ini kita pakai $\lambda = 0{,}5$.
- $\mathbf{x}_{\text{baru}}$ — pasien buatan hasil hitungan.

4.3 Membuat pasien baru #1 (di antara P6 dan P7)

Kita hitung tiap ciri satu per satu:

$$\begin{aligned}
\text{Usia} &= 45 + 0{,}5 \times (60 - 45) = 45 + 0{,}5 \times 15 = 45 + 7{,}5 = 52{,}5 \\
\text{Kepatuhan} &= 0 + 0{,}5 \times (0 - 0) = 0 \\
\text{Berat} &= 60 + 0{,}5 \times (65 - 60) = 60 + 0{,}5 \times 5 = 60 + 2{,}5 = 62{,}5
\end{aligned}$$

$$\mathbf{x}_{\text{baru\#1}} = (52{,}5;\ 0;\ 62{,}5) \quad \text{dengan hasil} = \text{Tidak Berhasil}$$

4.4 Membuat pasien baru #2 (di antara P7 dan P8)

$$\begin{aligned}
\text{Usia} &= 60 + 0{,}5 \times (35 - 60) = 60 + 0{,}5 \times (-25) = 60 - 12{,}5 = 47{,}5 \\
\text{Kepatuhan} &= 0 + 0{,}5 \times (0 - 0) = 0 \\
\text{Berat} &= 65 + 0{,}5 \times (70 - 65) = 65 + 2{,}5 = 67{,}5
\end{aligned}$$

$$\mathbf{x}_{\text{baru\#2}} = (47{,}5;\ 0;\ 67{,}5) \quad \text{dengan hasil} = \text{Tidak Berhasil}$$

Sebelum SMOTE jumlahnya 5 : 3. Kita tambahkan dua pasien buatan ke kelompok "Tidak Berhasil", sehingga menjadi **5 : 5** — **seimbang**. Data kini siap dipakai melatih pohon.

Kelompok	Sebelum SMOTE	Sesudah SMOTE
Berhasil	5	5
Tidak Berhasil	3	5
Total	**8**	**10**

5. Langkah 4 — Pohon Keputusan dan Indeks Gini

5.1 Seperti permainan "tebak-tebakan"

Pohon keputusan bekerja seperti permainan menebak: ia mengajukan pertanyaan ya/tidak, lalu mengikuti jawabannya ke pertanyaan berikutnya, sampai tiba di sebuah jawaban akhir. Contoh pertanyaan: *"Apakah kepatuhan pasien = Patuh?"* atau *"Apakah berat badannya* $\leq 57{,}5$*?"*.

Pertanyaannya: bagaimana pohon memilih pertanyaan yang *paling baik*? Di sinilah indeks Gini berperan.

5.2 Indeks Gini: mengukur "seberapa campur"

Bayangkan isi sebuah kantong kelereng. Kalau semua kelerengnya merah, kantong itu "bersih" (sejenis). Kalau campur merah dan biru, kantong itu "campur". Gini mengukur tingkat kecampuran ini: **0 berarti benar-benar bersih**, semakin besar berarti semakin campur.

$$\text{Gini}(t) = 1 - \sum_{k=1}^{K} p_k^2$$

Di sini p_k adalah bagian anggota kelas ke-k di dalam sebuah simpul t. Untuk masalah dua kelas (Berhasil dan Tidak Berhasil), rumusnya menyederhana menjadi:

$$\text{Gini} = 1 - (p_0)^2 - (p_1)^2$$

5.3 Menghitung Gini sebelum bertanya

Isi seluruh data kita sekarang 5 "Berhasil" dan 5 "Tidak Berhasil" dari 10 data:

$$p_0 = \tfrac{5}{10} = 0{,}5, \qquad p_1 = \tfrac{5}{10} = 0{,}5$$

$$\text{Gini} = 1 - (0{,}5)^2 - (0{,}5)^2 = 1 - 0{,}25 - 0{,}25 = 0{,}5$$

Nilai 0,5 berarti datanya cukup campur — masih "kotor".

5.4 Menghitung Gini setelah bertanya: "Kepatuhan $\leq 0{,}5$?"

Pertanyaan ini membelah data menjadi dua kelompok. Perhatikan bahwa "Kepatuhan $\leq 0{,}5$" artinya "Tidak Patuh" (karena Patuh = 1).

Kelompok kiri (Tidak Patuh): berisi P5, P6, P7, P8, S1, S2 $\rightarrow$ 6 data, yaitu 1 "Berhasil" dan 5 "Tidak Berhasil".

$$p_0 = \tfrac{1}{6} \approx 0{,}167, \qquad p_1 = \tfrac{5}{6} \approx 0{,}833$$

$$\text{Gini}_{\text{kiri}} = 1 - (0{,}167)^2 - (0{,}833)^2 = 1 - 0{,}028 - 0{,}694 = 0{,}278$$

Kelompok kanan (Patuh): berisi P1, P2, P3, P4 → 4 data, semuanya "Berhasil" (bersih).

$$\text{Gini}_{\text{kanan}} = 1 - (1)^2 - (0)^2 = 0$$

Gini gabungan. Kita gabungkan dengan menimbang banyaknya data tiap kelompok:

$$\text{Gini}_{\text{gabungan}} = \frac{6}{10}(0{,}278) + \frac{4}{10}(0) = 0{,}167 + 0 = 0{,}167$$

5.5 Membandingkan beberapa pertanyaan

Kita uji beberapa pertanyaan, lalu pilih yang Gini-nya paling kecil (paling bersih):

Pertanyaan	Gini gabungan
(tidak bertanya)	0,500
"Usia $\leq$ 37,5?"	0,476
"Kepatuhan $\leq$ 0,5?"	0,167
"Berat Badan $\leq$ 57,5?"	0,167

Pertanyaan **"Kepatuhan $\leq$ 0,5?"** (dan "Berat Badan $\leq$ 57,5?") memberi Gini paling kecil, 0,167 — jauh lebih bersih daripada 0,5 semula. Pertanyaan inilah yang dipakai pohon. (Kalau ada dua yang sama bagus, pohon boleh memilih salah satunya.)

5.6 Menyusun pohonnya

Dengan mengulang cara yang sama pada tiap cabang, terbentuklah pohon. Kita buat **tiga pohon** yang sedikit berbeda, agar nanti bisa saling melengkapi:

Pohon 1

Kepatuhan $\leq$ 0,5?
- ⊢ Ya → Berat $\leq$ 57,5?
  - ⊢ Ya → Berhasil
  - ⊢ Tidak → Tidak Berhasil
- ⊢ Tidak → Berhasil

Pohon 2

Berat $\leq$ 57,5?
- ⊢ Ya → Berhasil
- ⊢ Tidak → Usia $\leq$ 30?
  - ⊢ Ya → Berhasil
  - ⊢ Tidak → Tidak Berhasil

Pohon 3

Berat $\leq$ 57,5?
- ⊢ Ya → Berhasil
- ⊢ Tidak → Kepatuhan $\leq$ 0,5?
  - ⊢ Ya → Tidak Berhasil
  - ⊢ Tidak → Berhasil

6. Langkah 5 — Random Forest: Banyak Pohon yang Memilih

6.1 Mengapa harus banyak pohon?

Satu pohon bisa keliru. Tapi kalau kita bertanya kepada *banyak* pohon dan mengambil suara terbanyak, jawabannya jauh lebih dapat dipercaya — seperti bertanya kepada beberapa dokter lalu mengambil kesimpulan bersama. Kumpulan pohon ini disebut **Random Forest** (hutan acak).

6.2 Rumus aslinya

$$\hat{y} = \text{mode}\{\, h_1(\mathbf{x}),\ h_2(\mathbf{x}),\ \ldots,\ h_T(\mathbf{x}) \,\}$$

Di sini $h_t(\mathbf{x})$ adalah jawaban pohon ke-t untuk pasien $\mathbf{x}$, dan T adalah jumlah pohon. Tanda mode berarti "ambil jawaban yang paling sering muncul".

6.3 Menguji pasien baru

Misalkan datang pasien baru: **usia 40**, **Patuh (1)**, **berat 60**. Setiap pohon kita tanyai satu per satu:

Pohon	Alur jawabannya	Suara
Pohon 1	Patuh (1) → tidak masuk "Ya" → **Berhasil**	Berhasil (0)
Pohon 2	Berat 60 > 57,5 → Usia 40 > 30 → **Tidak Berhasil**	Tidak Berhasil (1)
Pohon 3	Berat 60 > 57,5 → Patuh (1) → **Berhasil**	Berhasil (0)

Suara: Berhasil = 2, Tidak Berhasil = 1

Karena "Berhasil" mendapat suara terbanyak (2 dari 3), hasil akhirnya: **Berhasil**.

7. Langkah 6 — Menghitung Tingkat Keyakinan

Keyakinan menunjukkan seberapa banyak pohon yang setuju dengan jawaban pemenang.

$$\text{Keyakinan} = \frac{\text{jumlah suara pemenang}}{T} \times 100\%$$

$$\text{Keyakinan} = \frac{2}{3} \times 100\% = 0{,}6667 \times 100\% = 66{,}67\%$$

Sistem **66,67% yakin** pasien tersebut akan **Berhasil**. Jika ketiga pohon setuju (3 dari 3), keyakinannya menjadi 100%.

8. Langkah 7 — Menilai Seberapa Tepat Tebakan

8.1 Menguji pada pasien yang jawabannya sudah diketahui

Kita uji sistem ke **6 pasien uji** yang hasil aslinya sudah kita ketahui, lalu bandingkan tebakan dengan kenyataan:

Uji	Usia	Patuh	Berat	Suara	Tebakan	Kenyataan
T1	32	1	48	0,0,0	Berhasil	Berhasil
T2	38	1	58	0,1,0	Berhasil	Berhasil
T3	44	1	63	0,1,0	Berhasil	Tidak Berhasil
T4	50	0	55	0,0,0	Berhasil	Berhasil
T5	62	0	66	1,1,1	Tidak Berhasil	Tidak Berhasil
T6	36	0	72	1,1,1	Tidak Berhasil	Tidak Berhasil

8.2 Confusion matrix

Hasil perbandingan itu kita rangkum dalam sebuah tabel bernama **confusion matrix**. Karena yang paling ingin kita deteksi adalah pasien **Tidak Berhasil** (kelompok minoritas), maka "Tidak Berhasil" dianggap sebagai kelas **positif**.

	Tebakan sistem		
Kenyataan	Berhasil	Tidak Berhasil	**Jumlah**
Berhasil	TN = 3	FP = 0	3
Tidak Berhasil	FN = 1	TP = 2	3
Jumlah	3	2	6

- **TP** (*True Positive*) = 2: pasien "Tidak Berhasil" yang *benar* ditebak Tidak Berhasil.
- **TN** (*True Negative*) = 3: pasien "Berhasil" yang *benar* ditebak Berhasil.
- **FP** (*False Positive*) = 0: pasien "Berhasil" yang *salah* ditebak Tidak Berhasil.
- **FN** (*False Negative*) = 1: pasien "Tidak Berhasil" yang *salah* ditebak Berhasil (paling berbahaya, karena pasien berisiko justru lolos).

8.3 Empat rumus penilaian

Akurasi — seberapa banyak tebakan yang benar secara keseluruhan:

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{2+3}{6} = \frac{5}{6} = 0{,}8333 = 83{,}33\%$$

Presisi — dari semua yang ditebak "Tidak Berhasil", berapa yang benar-benar begitu:

$$\text{Presisi} = \frac{TP}{TP + FP} = \frac{2}{2+0} = 1 = 100\%$$

Recall — dari semua yang benar-benar "Tidak Berhasil", berapa yang berhasil ditemukan:

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{2}{2+1} = 0{,}6667 = 66{,}67\%$$

F1-score — keseimbangan antara presisi dan recall:

$$F1 = 2 \cdot \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} = 2 \cdot \frac{1 \times 0{,}6667}{1 + 0{,}6667} = \frac{1{,}3333}{1{,}6667} = 0{,}8 = 80\%$$

Metrik	Nilai	Artinya
Akurasi	83,33%	5 dari 6 tebakan benar
Presisi	100%	yang ditebak "Tidak Berhasil" selalu benar
Recall	66,67%	2 dari 3 "Tidak Berhasil" berhasil ditemukan
F1-score	80%	gabungan presisi dan recall

9. Rangkuman: Perjalanan dari Data sampai Hasil

Mari kita lihat kembali seluruh perjalanannya dalam satu tarikan napas:

1. **Data.** 8 pasien: 5 Berhasil, 3 Tidak Berhasil (tidak seimbang).
2. **Encoding.** Patuh = 1, Tidak Patuh = 0; Berhasil = 0, Tidak Berhasil = 1.
3. **Jarak.** Cari pasien yang mirip, misalnya P6–P8 berjarak 14,14.

4. **SMOTE.** Buat 2 pasien buatan (S1 dan S2) → kelas jadi seimbang 5 : 5.
5. **Gini.** Pilih pertanyaan paling bersih (0,167 < 0,5).
6. **Pohon.** Susun 3 pohon dari pertanyaan-pertanyaan itu.
7. **Voting.** 3 pohon memberi suara → pemenangnya "Berhasil" (2 dari 3).
8. **Keyakinan.** $(2 \div 3) \times 100\% = 66{,}67\%$.
9. **Penilaian.** Akurasi 83,33%, presisi 100%, recall 66,67%, F1 80%.

Catatan

Contoh ini sengaja dikecilkan (3 ciri, 8 pasien, 3 pohon) agar bisa dihitung dengan tangan. Model pada penelitian sesungguhnya lebih besar — 175 baris data, 17 variabel, dan 100 pohon — namun **langkah-langkahnya sama persis**; hanya diulang lebih banyak kali. Jadi kalau kita paham contoh kecil ini, kita paham juga cara kerja model yang sebenarnya.