PERHITUNGAN MANUAL

SMOTE & Random Forest — Langkah demi Langkah, dari Data sampai Hasil

Isi

1. Data contoh (8 pasien)
2. Ubah kata menjadi angka
3. Menghitung jarak antara dua pasien
4. SMOTE: membuat pasien baru
5. Mencari pertanyaan terbaik (indeks Gini)
6. Menyusun pohon keputusan
7. Tiga pohon bersuara (voting)
8. Menghitung keyakinan
9. Menilai hasil (confusion matrix & metrik)
10. Rangkuman

0. Apa yang akan kita hitung?

Bayangkan kita punya catatan **8 pasien** MDR-TB. Dari catatan itu, kita ingin menebak: apakah pengobatan seorang pasien akan **Berhasil** atau **Tidak Berhasil**?

Komputer melakukan ini dengan dua cara, dan kita akan menghitungnya dengan tangan:

1. **SMOTE** — membuat “pasien buatan” baru supaya jumlah kedua kelompok seimbang.
2. **Random Forest** — banyak pohon keputusan yang masing-masing “memilih”, lalu dipilih suara terbanyak.

Setelah itu kita nilai seberapa tepat tebakannya.



1. Data contoh

Kita pakai 3 ciri (variabel) saja supaya mudah dihitung: **Usia**, **Kepatuhan Minum Obat**, dan **Berat Badan**. Kolom terakhir adalah kenyataan (jawaban yang benar).

Pasien	Usia	Kepatuhan Minum Obat	Berat Badan	Hasil (kenyataan)
P1	30	Patuh	50	Berhasil
P2	40	Patuh	55	Berhasil
P3	25	Patuh	60	Berhasil
P4	55	Patuh	45	Berhasil
P5	50	Tidak Patuh	55	Berhasil
P6	45	Tidak Patuh	60	Tidak Berhasil
P7	60	Tidak Patuh	65	Tidak Berhasil

P8	35	Tidak Patuh	70	Tidak Berhasil

Jumlah: **5 Berhasil** dan **3 Tidak Berhasil**. Kelompok “Tidak Berhasil” lebih sedikit — inilah yang disebut **data tidak seimbang**.

2. Ubah kata menjadi angka

Komputer tidak mengerti kata seperti “Patuh”. Jadi setiap kata diganti angka:

Kata	Angka
Patuh	1
Tidak Patuh	0
Berhasil	0
Tidak Berhasil	1

Hasilnya:

Pasien	Usia	Kepatuhan	Berat Badan	Hasil
P1	30	1	50	0
P2	40	1	55	0
P3	25	1	60	0
P4	55	1	45	0
P5	50	0	55	0
P6	45	0	60	1
P7	60	0	65	1
P8	35	0	70	1

> **Catatan tentang “samakan skala”.** Pada sistem sebenarnya, angka-angka ini disamakan dulu skalanya (dinormalisasi) agar Usia dan Berat Badan sama-sama “adil” saat diukur jaraknya. Di perhitungan tangan ini kita pakai angka aslinya supaya lebih mudah dibaca; caranya tetap sama.

3. Menghitung jarak antara dua pasien

SMOTE butuh tahu pasien mana yang “mirip”. Kami mengukur kemiripan dengan **jarak**: makin kecil jaraknya, makin mirip. Rumusnya (jarak Euclidean):

$$\text{Jarak} = \sqrt{(\text{Usia}_1 - \text{Usia}_2)^2 + (\text{Kepatuhan}_1 - \text{Kepatuhan}_2)^2 + (\text{BB}_1 - \text{BB}_2)^2}$$

Contoh: jarak antara **P6** dan **P7**.

$$\text{Usia} : (45 - 60)^2 = (-15)^2 = 225$$
$$\text{Kepatuhan} : (0 - 0)^2 = 0^2 = 0$$

```
Berat     : (60 − 65)² = (−5)² = 25

Jumlah = 225 + 0 + 25 = 250
Jarak  = √250 ≈ 15,81
```

Semua jarak antar pasien “Tidak Berhasil” (P6, P7, P8):

Pasangan	Hitungan	Jarak
P6 – P7	√250	15,81
P6 – P8	√200	14,14
P7 – P8	√650	25,50

Hasil

Pasien yang paling mirip dengan **P6** adalah **P8** (jarak 14,14 — paling kecil). Pasangan **P6–P7** dan **P7–P8** juga dipakai untuk contoh berikutnya.

4. SMOTE: membuat pasien baru

SMOTE membuat pasien baru **di antara** dua pasien “Tidak Berhasil” yang mirip. Pasien baru diletakkan di tengah-tengah (atau di sepanjang garis penghubungnya). Rumusnya:

```
Pasien baru = X + λ × (X_tetangga − X)

X = pasien asal,  X_tetangga = pasien mirip,
λ (lambda) = angka acak antara 0 dan 1. Di sini kita pakai λ = 0,5 (tengah-tengah).
```

Pasien baru #1 (antara P6 dan P7)

```
Usia      : 45 + 0,5 × (60 − 45) = 45 + 0,5 × 15 = 45 + 7,5  = 52,5
Kepatuhan : 0  + 0,5 × (0 − 0)   = 0  + 0          = 0
Berat     : 60 + 0,5 × (65 − 60) = 60 + 0,5 × 5    = 60 + 2,5  = 62,5

→ Pasien baru #1 = (52,5 ; 0 ; 62,5)   Hasil = Tidak Berhasil
```

Pasien baru #2 (antara P7 dan P8)

```
Usia      : 60 + 0,5 × (35 − 60) = 60 + 0,5 × (−25) = 60 − 12,5 = 47,5
Kepatuhan : 0  + 0,5 × (0 − 0)    = 0
Berat     : 65 + 0,5 × (70 − 65)  = 65 + 2,5 = 67,5

→ Pasien baru #2 = (47,5 ; 0 ; 67,5)   Hasil = Tidak Berhasil
```

Sekarang jumlahnya menjadi:

Kelompok	Sebelum SMOTE	Sesudah SMOTE

Berhasil	5	5
Tidak Berhasil	3	5
Total	**8**	**10**

Hasil

Kedua kelompok sekarang **seimbang** (5 dan 5). Dua pasien buatan (S1 dan S2) ditambahkan ke kelompok “Tidak Berhasil”. Data siap dipakai melatih pohon.

5. Mencari pertanyaan terbaik (indeks Gini)

Pohon keputusan bekerja seperti permainan tebak-tebakan. Ia mengajukan pertanyaan, misalnya “Apakah Kepatuhan = Patuh?” atau “Apakah Berat Badan ≤ 57,5?”. Untuk memilih pertanyaan terbaik, ia memakai **indeks Gini**: seberapa **campur** sebuah kelompok. Nilai 0 = benar-benar bersih, makin besar makin campur.

```
Gini = 1 − ( p₀ )² − ( p₁ )²

p₀ = bagian anggota kelompok “Berhasil”      (0)
p₁ = bagian anggota kelompok “Tidak Berhasil” (1)
```

Langkah A — Gini sebelum bertanya (semua 10 data)

```
Ada 5 “Berhasil” dan 5 “Tidak Berhasil” dari 10 data:
p₀ = 5/10 = 0,5      p₁ = 5/10 = 0,5

Gini = 1 − (0,5)² − (0,5)²
     = 1 − 0,25 − 0,25
     = 0,5   (cukup campur)
```

Langkah B — Coba pertanyaan: “Kepatuhan ≤ 0,5?” (= Tidak Patuh)

Pertanyaan ini memecah data menjadi dua kelompok:

```
KIRI  (Tidak Patuh) : P5, P6, P7, P8, S1, S2  → 6 data
                      isi: 1 “Berhasil” + 5 “Tidak Berhasil”
        p₀ = 1/6 ≈ 0,167     p₁ = 5/6 ≈ 0,833
        Gini = 1 − (0,167)² − (0,833)²
             = 1 − 0,0278 − 0,6944
             = 0,2778

KANAN (Patuh)       : P1, P2, P3, P4  → 4 data
        isi: semuanya “Berhasil” (bersih)
        Gini = 1 − (1)² − (0)² = 0

Gini gabungan = (bobot kiri × Gini kiri) + (bobot kanan × Gini kanan)
              = (6/10 × 0,2778) + (4/10 × 0)
```

```
                = 0,1667 + 0
                = 0,1667
```

Pertanyaan	Gini gabungan	Kesimpulan
(tidak bertanya)	0,5	paling campur
“Kepatuhan ≤ 0,5?”	0,1667	**paling bersih → dipilih**

Hasil

Karena 0,1667 jauh lebih kecil dari 0,5, pertanyaan **“Kepatuhan ≤ 0,5?”** adalah pertanyaan yang bagus, dan dipakai sebagai pertanyaan pertama pohon.

6. Menyusun pohon keputusan

Dengan pertanyaan-pertanyaan yang dipilih, kita gambar pohonnya. Kita buat **3 pohon** supaya bisa saling menutupi kelemahan (itulah gunanya “hutan”). Tiap pohon memakai pertanyaan yang sedikit berbeda.

Pohon 1

```
Apakah Kepatuhan ≤ 0,5?  (Tidak Patuh?)
│
├─ YA  → Apakah Berat Badan ≤ 57,5?
│        ├─ YA  → Berhasil
│        └─ TIDAK → Tidak Berhasil
│
└─ TIDAK (Patuh) → Berhasil
```

Pohon 2

```
Apakah Berat Badan ≤ 57,5?
│
├─ YA  → Berhasil
│
└─ TIDAK → Apakah Usia ≤ 30?
           ├─ YA  → Berhasil
           └─ TIDAK → Tidak Berhasil
```

Pohon 3

```
Apakah Berat Badan ≤ 57,5?
│
├─ YA  → Berhasil
│
└─ TIDAK → Apakah Kepatuhan ≤ 0,5?  (Tidak Patuh?)
           ├─ YA  → Tidak Berhasil
           └─ TIDAK (Patuh) → Berhasil
```

> Cara membacanya: mulai dari atas, jawab tiap pertanyaan, ikuti cabangnya sampai ketemu jawaban akhir (**Berhasil** atau **Tidak Berhasil**).

7. Tiga pohon bersuara (voting)

Sekarang ada pasien baru: **Usia 40**, **Kepatuhan Patuh (1)**, **Berat Badan 60**. Setiap pohon "menjawab", lalu kita hitung suaranya.

Pohon	Jalan pertanyaannya	Suara
Pohon 1	Kepatuhan = 1 (Patuh) → tidak masuk "YA" → **Berhasil**	Berhasil (0)
Pohon 2	BB = 60 > 57,5 → Usia 40 > 30 → **Tidak Berhasil**	Tidak Berhasil (1)
Pohon 3	BB = 60 > 57,5 → Kepatuhan = 1 > 0,5 → **Berhasil**	Berhasil (0)

```
Suara:  Berhasil = 2 suara
        Tidak Berhasil = 1 suara

Pemenang = yang suaranya terbanyak = Berhasil
```

Hasil

Hasil akhir untuk pasien baru = **Berhasil** (menang 2 suara dari 3).

8. Menghitung keyakinan

Keyakinan = seberapa banyak pohon yang setuju dengan jawaban pemenang.

```
Keyakinan = (suara pemenang ÷ jumlah pohon) × 100%
          = (2 ÷ 3) × 100%
          = 0,6667 × 100%
          = 66,67%
```

Hasil

Sistem **66,67% yakin** pasien tersebut akan **Berhasil**. Kalau ketiga pohon setuju (3 dari 3), keyakinannya = 100%.

9. Menilai hasil (confusion matrix & metrik)

Kita uji sistem ke **6 pasien uji** yang jawabannya sudah kita tahu. Bandingkan tebakan sistem dengan kenyataan.

Pasien uji	Usia	Kepatuhan	Berat	Suara 3 pohon	Tebakan	Kenyataan
T1	32	1	48	0,0,0	Berhasil	Berhasil
T2	38	1	58	0,1,0	Berhasil	Berhasil
T3	44	1	63	0,1,0	Berhasil	Tidak Berhasil

T4	50	0	55	0,0,0	Berhasil	Berhasil
T5	62	0	66	1,1,1	Tidak Berhasil	Tidak Berhasil
T6	36	0	72	1,1,1	Tidak Berhasil	Tidak Berhasil

Kita rangkum ke dalam **confusion matrix**. Karena yang ingin kita deteksi adalah pasien yang **Tidak Berhasil** (kelompok yang lebih jarang), maka "Tidak Berhasil" dianggap sebagai kelas **positif**.

Kenyataan	Tebakan sistem		Jumlah
	Berhasil	Tidak Berhasil	
Berhasil	**TN = 3**	FP = 0	3
Tidak Berhasil	**FN = 1**	**TP = 2**	3
Jumlah	3	2	6

- **TP (True Positive) = 2** — "Tidak Berhasil" yang **benar** ditebak Tidak Berhasil.
- **TN (True Negative) = 3** — "Berhasil" yang **benar** ditebak Berhasil.
- **FP (False Positive) = 0** — "Berhasil" tapi **salah** ditebak Tidak Berhasil.
- **FN (False Negative) = 1** — "Tidak Berhasil" tapi **salah** ditebak Berhasil (paling berbahaya).

a. Akurasi — seberapa banyak tebakan yang benar

```
Akurasi = (TP + TN) ÷ seluruh data
        = (2 + 3) ÷ 6
        = 5 ÷ 6
        = 0,8333
        = 83,33%
```

b. Presisi — dari yang ditebak "Tidak Berhasil", berapa yang benar-benar begitu

```
Presisi = TP ÷ (TP + FP)
        = 2 ÷ (2 + 0)
        = 2 ÷ 2
        = 1
        = 100%
```

c. Recall — dari semua yang benar-benar "Tidak Berhasil", berapa yang berhasil ditemukan

```
Recall = TP ÷ (TP + FN)
       = 2 ÷ (2 + 1)
       = 2 ÷ 3
       = 0,6667
       = 66,67%
```

d. F1-score — keseimbangan antara presisi dan recall

```
F1 = 2 × (Presisi × Recall) ÷ (Presisi + Recall)
   = 2 × (1 × 0,6667) ÷ (1 + 0,6667)
```

```
= 1,3333 ÷ 1,6667
= 0,8
= 80%
```

Hasil penilaian

Metrik	Nilai	Artinya
Akurasi	83,33%	5 dari 6 tebakan benar
Presisi	100%	yang ditebak “Tidak Berhasil” selalu benar
Recall	66,67%	2 dari 3 “Tidak Berhasil” berhasil ditemukan
F1-score	80%	gabungan presisi & recall

10. Rangkuman

Beginilah alur lengkapnya dari awal sampai akhir:

1. **Data**: 8 pasien (5 Berhasil, 3 Tidak Berhasil).
2. **Ubah kata jadi angka**: Patuh=1, Tidak Patuh=0, Berhasil=0, Tidak Berhasil=1.
3. **Hitung jarak**: cari pasien yang mirip (mis. P6–P8 jarak 14,14).
4. **SMOTE**: buat 2 pasien buatan → jumlah jadi seimbang 5 : 5.
5. **Indeks Gini**: pilih pertanyaan paling “bersih” (Gini 0,1667 < 0,5).
6. **Pohon**: susun pohon dari pertanyaan-pertanyaan itu.
7. **Voting**: 3 pohon memilih → suara terbanyak menang (Berhasil, 2 dari 3).
8. **Keyakinan**: (2 ÷ 3) × 100% = 66,67%.
9. **Penilaian**: akurasi 83,33%, presisi 100%, recall 66,67%, F1 80%.

> **Catatan:** contoh ini memakai 3 pohon dan 3 ciri saja agar bisa dihitung dengan tangan. Model pada penelitian sebenarnya memakai lebih banyak data (175 baris), 17 variabel, dan 100 pohon — tetapi **langkah-langkahnya persis sama** seperti di atas, hanya diulang lebih banyak.